

Alphalens Backtrader Qlib

三因子实战学习手册

使用 Tushare 真实沪深 300 数据的完整学习路径

适合对象 GitHub 和 Python 量化初学者

数据区间 2021 年 1 月到 2025 年 12 月

文稿版本 2026 年 9 月

如何使用本手册

本手册不是三个仓库 README 的翻译，而是一条可以实际运行的学习路线。同一份真实价格数据先进入 Alphalens 检查因子，再进入 Backtrader 验证交易规则，最后进入 Qlib 学习模型组合。三个阶段分别回答不同问题，不能互相替代。

阶段	工具	回答的问题	本项目入口
因子诊断	Alphalens	因子和未来收益是否存在统计关系	three_factors_analysis.py
策略回测	Backtrader	按因子调仓并考虑资金手续费后表现如何	three_factor_backtest.py
模型学习	Qlib	模型能否学习三个因子的非线性组合	three_factor_qlib.py

推荐学习顺序：先完整运行一次，再按本手册的函数地图逐段阅读代码，最后只修改一个参数并观察结果变化。

项目目录和 Python 环境

```
计算金融/  
  data/tushare_csi300/      # 真实行情和元数据  
  labs/alphalens/          # 因子分析  
  labs/backtrader/         # 组合回测  
  labs/qlib/               # 机器学习实验  
  repositories/           # 可选：本地克隆的官方源码，不上传  
  output/                 # 所有运行结果  
  quant_finance.code-workspace # VS Code 总工作区
```

目录	解释器	主要包
02 Alphalens	.venv-alphalens\Scripts\python.exe	alphalens pandas matplotlib PyQt5 tushare
01 Backtrader	.venv-backtrader\Scripts\python.exe	backtrader pandas numpy matplotlib PyQt5
03 Qlib	.venv-qlib\Scripts\python.exe	pyqlib lightgbm pandas sklearn matplotlib PyQt5

真实数据和三个因子

数据表结构

核心输入文件是 data/tushare_csi300/csi300_qfq_close_2021_2025.csv。每一行是交易日，每一列是股票代码，单元格是 Tushare 前复权收盘价。本次下载得到 1212 个交易日和 300 只股票，整体价格缺失率为 2.55%。

文件	用途	是否直接参与计算
csi300_qfq_close_2021_2025.csv	真实前复权收盘价宽表	是
csi300_constituent_weights_202512.csv	2025 年末沪深 300 股票池和权重	用于确定股票池
data_quality.csv	逐只股票的日期范围和下载状态	检查用
metadata.json	接口、日期、复权和限制说明	说明用

前复权口径说明：Tushare 的 pro_bar 使用查询 end_date 作为动态前复权基准。本项目研究区间截至 2025 年 12 月 31 日，因此历史绝对价格可能与同花顺当前前复权价不同。三个因子使用价格比率和收益率，统一缩放不会改变因子值。

因子一 20 日动量

$$MOM_{20}(t, i) = P(t, i) / P(t-20, i) - 1$$

P 表示前复权收盘价，因子越高表示过去 20 日涨幅越大

直觉是价格趋势可能在短期延续。代码用 prices / prices.shift(20) - 1 计算。

因子二 5 日反转

$$REV_5(t, i) = -[P(t, i) / P(t-5, i) - 1]$$

过去 5 日收益前加负号，近期跌得越多，因子越高

直觉是短期过度上涨或下跌可能回归。负号把因子方向统一为数值越高越好。

因子三 20 日低波动

$$LOWVOL_{20}(t, i) = -Std[r(t-19, i), ..., r(t, i)]$$

r 表示日收益率；代码计算 20 日滚动标准差且自动填充缺失价

Alphalens 因子有效性分析

它在流程中的位置

Alphalens 不负责下单，也不负责训练机器学习模型。它把每天每只股票的因子值与未来 1 日、5 日收益对齐，再计算 Rank IC 和分组收益。首先看统计关系，再决定是否值得进入策略回测。

主要函数地图

函数	输入	输出和作用
load_real_prices	真实 CSV 路径	只读取真实价格；文件缺失时立即报错
validate_prices	价格宽表	检查日期、重复项、非法价格和缺失率
calculate_factors	价格宽表	返回三个日期乘股票的因子宽表
wide_factor_to_series	单个因子宽表	转换为 date 和 asset 双层索引 Series
analyze_factor	因子 Series 和价格	调用 Alphalens 清洗、未来收益、IC 和分组收益
create_combined_chart	三个因子的结果	生成三行三列对比图
main	无	串联读取、计算、分析、保存和弹窗

关键代码理解

```
factor_data = al.utils.get_clean_factor_and_forward_returns(  
    factor=factor, prices=prices, periods=(1, 5), quantiles=5  
)  
rank_ic = al.performance.factor_information_coefficient(factor_data)  
mean_returns, _ = al.performance.mean_return_by_quantile(factor_data)
```

get_clean_factor_and_forward_returns 是最核心的入口。它负责日期和股票对齐、计算未来收益、按每日横截面将因子分成五组。Rank IC 是因子排名与未来收益排名的 Spearman 相关系数。

Alphalens native plotting for three factors




图1 真实沪深300 数据上的三个因子Alphalens 诊断图

因子	平均 1 日 Rank IC	平均 5 日 Rank IC	初步判断
20 日动量	-0.0144	-0.0156	样本中方向偏弱且略为反向
5 日反转	0.0227	0.0090	存在较弱正相关
20 日低波动	0.0344	0.0321	三者中 IC 相对最高，但仍需看分组稳定性

Backtrader 三因子组合回测

策略规则

- 每天分别计算 20 日动量、5 日反转和 20 日低波动。
- 把每个因子转换为当日横截面百分位排名，再等权平均成综合分数。
- 从第 21 个交易日起，每 20 个交易日调仓一次。
- 等权持有综合分数最高的 20 只股票，目标总仓位 90%。
- 佣金按双边万分之三演示，订单在下一根 K 线执行。

主要类和函数地图

代码单元	职责	初学者重点
PandasThreeFactorData	扩展 Backtrader 数据 feed	给标准 OHLC 增加三个因子和综合分数 line
add_stock_feeds	逐只股票创建数据源	不把缺失价格填成 0；当前 OHLC 都用收盘价演示
ThreeFactorPortfolio.prenext	部分股票尚未上市时仍运行	避免等待最后一只股票上市才开始回测
ThreeFactorPortfolio.next	选股、卖出和目标权重下单	当前日产生信号，下一根 K 线成交
notify_order	记录失败订单	本次实测失败订单为 0
save_results	计算并保存绩效	资金曲线、年化收益、波动、夏普和回撤
plot_results	保存和显示图形	F5 时使用 Qt5Agg 弹窗

事件驱动逻辑

```
if (len(self) - WARMUP_DAYS - 1) % REBALANCE_EVERY != 0:
    return
selected = sorted(candidates, reverse=True)[:TOP_N]
self.order_target_percent(data=data, target=0.90 / len(selected))
```

Backtrader 不是一次性向量计算。它让时间逐日推进，每天调用 next。订单对象、持仓、现金和手续费由 broker 管理。本例先发出清仓指令，再发出目标权重指令，并保留 10% 现金缓冲，降低同时换仓时的资金不足风险。




图2 三因子组合与等权股票池的资金曲线及策略回撤

指标	本次结果	含义
总收益	15.47%	100 万元期末约 115.47 万元
年化收益	3.04%	按 252 个交易日折算
年化波动	15.08%	日收益标准差年化
夏普比率	0.274	示例使用无风险利率 0
最大回撤	21.73%	历史高点到随后低点的最大跌幅
订单失败	0	60 次调仓均未发生 Margin 或 Rejected

解释时必须同时看基准。图中策略明显落后于简单等权股票池，说明“因子有统计相关”不等于“当前组合规则能够跑赢基准”。这正是 Backtrader 阶段的价值：把抽象因子转化成真实的仓位和交易规则后重新检验。

Qlib 三因子机器学习实验

数据流

真实价格宽表

-> 三个因子每日百分位排名

-> StaticDataLoader

-> DataHandlerLP

-> DatasetH(train / valid / test)

-> Qlib LGBModel

-> 2025 年预测、Rank IC 和分组收益

StaticDataLoader 适合已经拥有 pandas 表格的学习者，不要求先把 CSV 转换为 Qlib 二进制数据。它仍然使用 Qlib 标准的 DataHandlerLP、DatasetH 和 LGBModel，所以可以学习 Qlib 的数据集和模型接口。

主要函数地图

函数	职责	关键点
build_qlib_table	生成三列特征和未来 5 日标签	特征只使用当日及历史数据；标签使用 shift(-5)
create_qlib_dataset	构造 Qlib 数据管线	feature 和 label 成为列的第一层分组
train_model	训练 Qlib LGBModel	2021 到 2023 训练，2024 验证并早停
prepare_test_predictions	对 2025 年测试集预测	按 datetime 和 instrument 双层索引对齐标签
calculate_daily_rank_ic	逐日 Spearman 相关	衡量横截面排序能力
calculate_non_overlapping_portfolios	每 5 日构造高低预测组	避免 5 日标签大量重叠后直接连乘
save_evaluation	保存指标和 MLflow 记录	随机种子只控制训练复现，不生成股票价格

模型训练代码

```
model = LGBModel(loss='mse', learning_rate=0.03, num_leaves=31)
model.fit(dataset, num_boost_round=300, early_stopping_rounds=30)
prediction = model.predict(dataset, segment='test')
```

LightGBM 是树模型，可以学习三个因子的阈值和非线性组合。本次训练在第 7 轮早停，表示继续增加树并没有改善 2024 验证集误差。早停不是错误，而是防止模型继续拟合训练噪声。




图3 Qlib 模型的因子重要性、Rank IC、诊断组合和预测分组收益

指标	2025 测试结果	解释
测试观测	70,821	日期和股票组成的有效样本数
平均日 Rank IC	0.0049	整体排序相关性很弱
日 ICIR	0.0473	平均 IC 相对 IC 波动较低
IC 为正比例	51.68%	略高于一半
预测最高组 5 日收益	1.294%	每 5 日非重叠诊断组合平均
预测最低组 5 日收益	0.553%	低预测组仍有正收益
高减低 5 日收益	0.741%	模型在测试期存在一定分组差异

平均 Rank IC 接近 0 而高低组仍有差异并不矛盾：模型可能只在分布两端有一定区分力，但对全部股票的完整排序能力较弱。结论应是“值得继续检验”，而不是“模型已经可交易”。

在 VS Code 中运行

第一次运行顺序

1. 双击 quant_finance.code-workspace 打开总工作区。
2. 在左侧打开 02 Alphalens，按 F5 选择“真实数据：运行三个因子分析”。
3. 在左侧打开 01 Backtrader，按 F5 选择“真实数据：Backtrader 三因子回测”。
4. 在左侧打开 03 Qlib，按 F5 选择“真实数据：Qlib 三因子模型”。
5. 等待终端出现“确认：使用 Tushare 真实数据”，查看弹窗，关闭窗口后程序结束。

启动项	大致耗时	结果目录
真实数据：运行三个因子分析	约 20 到 30 秒	output/alphalens_three_factors
真实数据：Backtrader 三因子回测	约 1 到 2 分钟	output/backtrader_three_factors
真实数据：Qlib 三因子模型	约 10 到 20 秒	output/qlib_three_factors

如何确认不是随机行情

- 终端会明确显示真实 CSV 路径、1212 个交易日和 300 只股票。
- 三个正式 F5 启动项都指向 data/tushare_csi300/csi300_qfq_close_2021_2025.csv。
- 真实 CSV 缺失时三个程序会直接报错，不会自动改用模拟数据。
- Qlib 中的随机种子 42 仅用于模型训练复现，不会生成或改变价格。

输出文件怎么读

结果文件	先看什么
factor_summary.csv	三个因子的 1 日和 5 日 IC、最高组减最低组收益
three_factors_diagnostics.png	分组是否单调、IC 是否长期同方向
backtest_metrics.csv	总收益、年化收益、夏普、最大回撤
rebalance_holdings.csv	每次选中了哪些股票和目标权重
backtest_result.png	策略是否跑赢等权基准、回撤发生在哪些时期
qlib_metrics.csv	测试期 IC、ICIR 和高低预测组差异
qlib_predictions.csv	逐日逐股票预测值和真实未来收益
qlib_feature_importance.csv	模型使用三个因子的相对程度

研究限制和下一步升级

必须写进课程报告的限制

限制	为什么重要	升级方向
固定 2025 年末成分股	回看 2021 年时包含后来成为成分股的公司，产生幸存者偏差	按月获取当时的历史成分股
只有收盘价	Backtrader 无法真实模拟下一日开盘成交和涨跌停	下载 OHLCV、停牌和涨跌停数据
手续费简化	未区分佣金、印花税、滑点和市场冲击	按 A 股买卖方向分别设置成本
等权综合因子	三个因子的权重没有优化，也没有行业中性化	加入行业、市值中性和权重稳健性检验
一次训练验证测试切分	结果可能依赖特定年份	采用滚动或扩展窗口重新训练
短期样本和单一市场	结论不保证跨时期和跨市场稳定	延长样本并做子样本、牛熊市检验

本项目是教学系统，不是投资建议。正确的学习结论不是寻找一条最漂亮的收益曲线，而是理解每一层假设如何影响结果，并能够用新的数据、时间区间和交易成本重复实验。

建议的四个练习

1. 把 Backtrader 的 TOP_N 从 20 改为 10 或 50，对比收益、波动和回撤。
2. 把调仓间隔从 20 日改为 5 日，观察手续费和换仓频率的影响。
3. 在 Qlib 中分别只保留一个因子，比较模型 IC 和分组收益。
4. 将 Qlib 测试年份改为 2024、验证年份改为 2023，检查结论是否依赖 2025。

常见报错速查

现象	原因	处理
Couldn't find debug adapter descriptor	VS Code Python 扩展未加载	完全重启 VS Code，再从工作区按 F5
ModuleNotFoundError	运行了错误的 Python 环境	使用各目录已经配置的 F5 启动项
未找到真实行情文件	下载尚未完成或文件被移动	重新运行 Tushare 下载启动项
图形窗口一直运行	plt.show 正在等待用户关闭窗口	查看完图表后关闭窗口
Dropped entries	因子历史不足或未来收益不足	少量删除属于正常，异常高时检查数据
Qlib early stopping	验证集误差不再改善	这是正常的防过拟合机制

逐文件学习索引

文件	用途	建议阅读顺序
labs/alphalens/download_tushare_csi300.py	调用 Tushare 并建立真实价格宽表	先看配置和 download_one_stock
labs/alphalens/three_factors_analysis.py	Alphalens 因子诊断	配置 → calculate_factors → analyze_factor → main
labs/backtrader/three_factor_backtest.py	事件驱动组合回测	数据 feed → Strategy → save_results → main
labs/qlib/three_factor_qlib.py	Qlib 数据集和 LightGBM 实验	build_qlib_table → DatasetH → model → evaluation
各目录/.vscode/launch.json	F5 启动配置和环境变量	理解 program、python、cwd 和 env
各目录/.vscode/settings.json	固定目录使用的 Python 解释器	理解为什么三个库不共用一个环境

仓库源码应该怎么看

不要从仓库第一行开始逐文件阅读。先运行 labs 中的短示例，遇到具体对象再打开官方仓库或本地克隆目录查源码。例如看到 al.performance.factor_information_coefficient 后再搜索 Alphalens 的 performance.py；看到 bt.Cerebro 后再搜索 Backtrader 的 cerebro.py；看到 DatasetH 后再搜索 Qlib 的 dataset 模块。

```
VS Code 全局搜索: Ctrl + Shift + F
搜索示例: factor_information_coefficient
搜索示例: class Cerebro
搜索示例: class DatasetH
```

参考链接

- Alphalens GitHub <https://github.com/quantopian/alphalens>
- Backtrader GitHub <https://github.com/mementum/backtrader>
- Qlib GitHub <https://github.com/microsoft/qlib>
- Tushare 日线接口 https://tushare.pro/document/2?doc_id=27
- Tushare 复权行情 https://tushare.pro/document/2?doc_id=146
- Tushare 指数权重 https://tushare.pro/document/2?doc_id=96